



Supervision des systèmes

Projet de détection d'intrusion basé sur Netflow Algorithme KGB

1 Introduction à l'algorithme KGB



4 Analyse des résultats



2 Exposé des traitements sur dataset



5 Perspectives d'amélioration



L'algorithme KGB





Introduction à l'algorithme KGB

ARTICLE

COMPUTERS & SECURITY AS (2014) 100-123



Available online at www.sciencedirect.com

ScienceDirect

Computers & Security

journal homepage: www.elsevier.com/locate/cose

An empirical comparison of botnet detection methods



S. García a,b,*, M. Grill , J. Stiborek , A. Zunino

* ISISTAN Research Institute — CONICET, Faculty of Sciences, UNICEN University, Argentina * Agents Technology Group, Department of Computer Science and Engineering, Cooch Technical University in Prague, Ceach Republic

ARTICLE INFO

Article history: Received 21 October 2013 Received in revised form 29 April 2014 Accepted 27 May 2014 Available colline 5 June 2014

Reywords: Botnet detection Malware detection Methods comparise Botnet dataset

ABSTRACT

The results of betree detection methods are usually presented without any comparison. Although it is governly scraped that more comparisons with third-upty methods may help to impreve the area, few papers could do it. Among the factors that prevent a comparison are the difficulties to share a stituest, the tack of a good dataset, the sheers of a proper description of the methods and the lack of a comparison methodology. This paper compares the output of three difference better detected methods betterd, menual and background traffic. The results of our two methods [Chica and CAMDNI'S) and better were compared to output of the difference of the comparison detection of the comparison of the comparison detection of the comparison of the confidence of the confidence of the comparison of the confidence of the confidence of the comparison of the confidence of the confidence of the comparison of the confidence of the confide

0 2014 Ebevier Ltd. All rights reserved.

1. Introduction

It is difficult to estimate how much a new bottest detection method improves the current results in the wars. It may be done by comparing the new results with other methods, but this has affready been proven hard to accomptible, (viv) and Hasberten, 2011). Among the factors that provent these comparisons are: the absence of proper documentation of the methods (Tevallace et al., 2016), the lack of a common, labeled and good bottest dataset (Houseve et al., 2013), the lack of a comparison methodology (viviv and Hasberten, 2013) and the lack of a suitable error metric Edwards is a comparison. Although the comparison of methods can greatly help to improve the bottet detection area, few proposals made such a comparison (Carcia et al., 2013). As far as we know, only three papers (Warzinger et al., 2016, Zhao et al., 2015, Li et al., 2010) made the effort so far.

Obtaining a good dataset for comparisons is difficult. Currently, most detection proposals tend to create their own botnet datasets to evaluate their methods. However, those datasets are difficult to create (just ed., 2009) and usually end up being suboptimal (Edizard et al., 2011), Le. they lack some important features, such as ground truth labels, heterogeneity or real-world traffic. These custom datasets are often difficult to use for comparison with other methods. This is because each

0167-4048/0 2014 Ebevier Ltd. All rights reserved

"An empirical comparison of botnet detection methods"

2014

Année de publication dans le cadre du journal Computers & Security



Auteurs affiliés à l'université **UNICEN University**, Argentina et **Czech Technical University**, Prague -S. García, M. Grill, J. Stiborek, A. Zunino

Article cité
1024 fois



Currequeding surbor. ESSTAN Research Institute-CONCCT, Faculty of Sciences, UNICEN University, Argentins.
 E-mail subfresses: substating periodicisten universe datur, eldrecodignal com (E. Goreth, pillbergents inferents; (M. Grill), jurnationablesynthis field; evector (E. Golden), skejende cuminolisiten universe chair (E. Zunime).

INTRODUCTION À L'ALGORITHME KGB



KGB est basé sur l'article de Pevny et al. (2012) "Identifying suspicious users in corporate networks"





Plus performant que les autres algorithmes



Temps d'entraînement plus long et énergivore



Le plus proche des solutions d'entreprise



Recherche de complexité



INTRODUCTION À L'ALGORITHME KGB



Basé sur les travaux de l'entropie de Lakhina, l'anomalie finale est déterminée à partir des écarts moyens

La méthode utilise les entropies des distributions d'adresses IP et de ports pour construire deux modes de détection





Il existe deux versions du détecteur KGB:



KGBf examine les composantes principales avec de fortes variances.



KGBfog examine les composantes principales avec de faibles variances.



Exposé des traitements sur dataset

CTU-13 DATASET





Dataset CTU-13

Captures réseau (2011, CTU University, République Tchèque)





Flux labellisés :

botnet, normal, background → Évaluation fiable.



Trafic mixte:

normal, malveillant, bruit de fond.



Scénario 10, idéal pour KGB :

DDoS UDP intense, contexte réaliste, variations statistiques marquées.



EXTRACTION ET CONVERSION DES DONNÉES

Fichiers .binetflow → **CSV** : Analyse simplifiée (pandas, scikit-learn...).

```
StartTime,Dur,Proto,SrcAddr,Sport,Dir,DstAddr,Dport,State,sTos,dTos,TotPkts,TotBytes,SrcBytes,Label 2011/08/18 10:21:46.633335,1.060248,tcp,93.45.239.29,1611, ->,147.32.84.118,6881,S_RA,0,0,4,252,132,flow=Background-TCP-Attempt 2011/08/18 10:19:49.027650,279.349152,tcp,62.240.166.118,1031, <?>,147.32.84.229,13363,SRPA_PA,0,0,15,1318,955,flow=Background-TCP-Attempt 2011/08/18 10:22:07.160628,166.390015,tcp,147.32.86.148,58067, ->,66.235.132.232,80,SR_SA,0,0,3,212,134,flow=Background-TCP-Established 2011/08/18 10:26:02.052163,1.187083,tcp,147.32.3.51,3130, ->,147.32.84.46,10010,S_RA,0,0,4,244,124,flow=Background-TCP-Attempt
```

Colonnes principales:

- → StartTime / Dur : début & durée du flux
- → **Proto**: protocole (TCP, UDP...)
- → SrcAddr / DstAddr : IP source & destination
- → Sport / Dport : ports source & destination

- → State : état de la connexion
- → TotPkts / TotBytes : paquets & octets échangés
- → **Label**: nature du trafic (Background, Botnet...)



NETTOYAGE ET TRANSFORMATION

Conversion des dates:

```
df['is_weekend'] = df['timestamp'].dt.weekday.apply(lambda x: 1 if x >= 5 else 0)
df['is_work_hours'] = df['timestamp'].dt.hour.apply(lambda h: 1 if 9 <= h < 17 else 0)</pre>
```

- → Flags temporels (heures de bureau, heures tardives...)
- is_weekend Flag binaire (1/0) indiquant si l'enregistrement a lieu durant le week-end. Calculé à partir de timestamp.dt.weekday (valeur 1 si >= 5).
- is_work_hours Flag binaire (1/0) indiquant si l'enregistrement se situe pendant les heures de travail (entre 9h et 17h).

Gestion des ports:

```
df['is_dst_port_well_known'] = (df['dst_port'] < 1024).astype(int)
df['is_src_port_well_known'] = (df['src_port'] < 1024).astype(int)</pre>
```

Détection de ports well-known (ex. < 1024) ou suspicious (liste prédéfinie, ex. 6667 pour IRC malveillant).



L'algorithme KGB

L'ALGORITHME KGB

Définition

KGB est un algorithme de détection d'anomalies qui, via l'analyse en composantes principales (PCA) sur la matrice d'entropie, sépare les grandes variances (composantes majeures) et les petites variances (composantes mineures) pour repérer à la fois les anomalies franches et les comportements anormaux plus subtils.



Entropie de Shannon : $\mathrm{H}(X) = -\sum_{i=1}^n \mathrm{P}(x_i) \log \mathrm{P}(x_i)$



PCA: Analyse en composantes principales




Distance de Mahalanobis :

$$f(x^t(\iota)) = \sum_{j=1}^k \frac{(y_j^T x^t(\iota))^2}{\lambda_j^2},$$

$$f(x^{t}(\iota)) = \sum_{j=1}^{k} \frac{(y_{j}^{T} x^{t}(\iota))^{2}}{\lambda_{j}^{2}},$$

$$f^{\perp}(x^{t}(\iota)) = \sum_{j=k+1}^{r} \frac{(y_{j}^{T} x^{t}(\iota))^{2}}{\lambda_{j}^{2}}.$$



L'ALGORITHME KGB

3 exemples d'entropie :

HsPr (entropie des ports sources) : variation des ports sources utilisés par un utilisateur.

HdPr (entropie des ports destinations) : diversité des ports vers lesquels l'utilisateur envoie du trafic.

HdIP (entropie des adresses IP de destination) : mesure de la dispersion des communications vers différentes IP.



Un utilisateur naviguant normalement sur le web aura une faible entropie de ports destination *HdPr* et une faible entropie d'adresses IP de destination *HdIP.*



Un utilisateur scannant les ports ouvert enverra du trafic vers un grand nombre de ports destination, ce qui augmentera l'entropie *HdIP*.



Explication étape par étape



- On groupe le Dataframe de donnée suivant l'IP source où on calcule l'entropie-type de chaque attribut par IP
 - On génère une matrice d'entropie normalisé avec les IP sources en ligne et les entropies-types en colonne
- On calcule une matrice PCA pour réduire la dimension des attributs en conservant les composantes principales
- L'analyse en composantes principales (PCA) identifie les directions majeures permettant d'expliquer la variance


- On divise ces composantes en deux catégories KGBf (composantes majeurs) et KGBfog (composantes mineures)
- On calcule la distance global de Mahalanobis pour KGBf et KGBfog
- On teste si la distance pour chaque IP source est supérieur à un des pourcentages des distances globals (KGBf et KGBfog)
- Si oui, c'est une anomalie. Si non, c'est normale.




LES HYPERPARAMÈTRES

- 1 Taille de l'échantillon
- Seuil en pourcentages de variance à expliquer

- 3 Nombre de composantes principales
 - 4 Seuil d'anomalie pour les composantes principales
 - 5 Seuil d'anomalie pour les composantes secondaires








L'ALGORITHME KGB



Détection des anomalies

Deux scores sont utilisés:

- Variance projetée sur les principales composantes (mesure de dispersion des comportements normaux).
- Variance dans l'espace résiduel (où les anomalies sont supposées se situer).




Si ces scores dépassent un seuil défini, l'utilisateur est identifié comme suspect.



Analyse des résultats

ANALYSE DES RÉSULTATS



Ajustement des hyperparamètres

- **n_major_components** : Nombre de composantes principales utilisées pour calculer le score majeur d'anomalie.
- threshold PCA: Pourcentage de la variance à conserver lors de la décomposition en composantes principales.
- threshold major: Seuil déterminant le niveau critique pour le score majeur, au-delà duquel une anomalie est suspectée.
- threshold minor: Seuil déterminant le niveau critique pour le score mineur, complétant l'analyse d'anomalies.


Score F1: 0.68971; Précision: 0.52637; Recall: 1.00










ANALYSE DES RÉSULTATS





École Mines-Télécom





19

Perspectives d'amélioration

AMÉLIORATIONS À IMPLÉMENTER



Sélection précise des attributs

Choisir les paramètres
réellement pertinents et
affiner les
hyperparamètres
pour maximiser la
performance de
l'algorithme KGB



Comparaison rigoureuse

Confronter la précision de nos résultats à ceux de l'article de référence pour évaluer l'apport de ces choix




Implémenter une solution plus efficace

Améliorer l'efficacité de la solution afin de viser une implémentation en temps réel, apte à détecter rapidement les anomalies sur des flots de données continus



Comparaison avec KBG

Algorithme alternatif - Modèle Génétique - Algorithme KBG - K-means Based Genetic









Merci!

Supervision des systèmes

Projet de détection d'intrusion basé sur Netflow Algorithme KGB